शोधसार

यस शोधप्रबन्धमा भिडियो कार्य पहिचानका लागि स्व-निरीक्षित भिडियो इन्कोडर र दृष्टि-भाषा मोडेलको तुलनात्मक प्रभावकारिता अध्ययन गरिएको छ। मौलिक रूपमा भिन्न शिक्षण प्रतिमान प्रतिनिधित्व गर्ने दुई अत्याधुनिक आधारभूत मोडेलहरू मूल्याङ्कन गरिएका छन्: V-JEPA 2 (६५.४ करोड प्यारामिटर) र Qwen2.5-VL (७ अर्ब प्यारामिटर) FineGym र HMDB51 बेन्चमार्कहरूमा फ्रोजन-फिचर मूल्याङ्कन प्रोटोकल प्रयोग गरिएको छ। निकालिएका प्रतिनिधित्वहरू नौ वर्गीकरणकर्तामा मूल्याङ्कन गरिएका छन्, जसमा बहु-तह अव्यक्त प्रतिनिधित्वहरू उपयोग गर्न डिजाइन गरिएको नवीन HAF-STD Net समावेश छ। FineGymमा, HAF-STD Netसँग V-JEPA 2ले ९८.१% Accuracy र ९७.८% Macro F1 हासिल गऱ्यो, जसले Qwen2.5-VLलाई ९.४ प्रतिशत बिन्दुले पछि पाऱ्यो। HMDB51मा, V-JEPA 2ले ८४.७% Accuracy र ८५.३% Macro F1 हासिल गऱ्यो, जसले Qwen2.5-VLलाई ६.२ प्रतिशत बिन्दुले पछि पाऱ्यो। नतिजाहरूले देखाउँछन् कि कार्य-विशिष्ट स्व-निरीक्षित भिडियो इन्कोडरहरूले सामान्य-उद्देश्यीय दृष्टि-भाषा मोडेलहरू भन्दा उल्लेखनीय रूपमा बढी विभेदकारी कालिक प्रतिनिधित्वहरू उत्पादन गर्छन्। यसबाहेक, प्रस्तावित HAF-STD Netले फ्रोजन स्व-निरीक्षित भिडियो ब्याकबोनहरूमा उल्लेखनीय कार्यसम्पादन सुधार गर्दछ।

शब्द कुञ्जिका: Video Understanding, Self-Supervised Learning, Vision-Language Models, Action Recognition, HAF-STD Net